

UNIVERSIDAD NACIONAL DE COLOMBIA

Facultad de Ciencias

Maestría en Ciencias Matemáticas Aplicadas

Propuesta de Tesis de Maestría en Ciencias - Matemática Aplicada

---

Reconstrucción de series temporales geotécnicas mediante procesos Gaussianos informados por un modelo constitutivo de roca

Autor: Alejandro Enrique Aguilar Sánchez

Director propuesto: Arles Ernesto Rodríguez Portela

Programa: Maestría en ciencias - Matemáticas aplicadas

Ciudad: Bogotá, 2026

Índice

1. Justificación y Planteamiento del Problema **2**
1.1. Trabajo previo . . . 2
1.2. El problema . . . 2
1.3. Posibles aportes . . . 6
1.3.1. Aporte 1: un marco de reconstrucción que entiende la física del macizo . . . 6
1.3.2. Aporte 2: usar un sensor para reconstruir otro . . . 6

2. Marco Teórico y Estado del Arte **7**
2.1. El problema de datos faltantes en monitoreo estructural y geotécnico . 7
2.2. Procesos Gaussianos: fundamentos matemáticos . . . 7
2.2.1. Funciones de covarianza relevantes . . . 8
2.3. Proceso Gaussiano Multivariado de salida múltiple . . . 9
2.4. Modelo constitutivo del macizo rocoso como restricción física . . . 10

3. Análisis Estadístico y Validación de la Hipótesis de Correlación **11**
3.1. Medidas de correlación clásica . . . 11
3.2. Medidas de dependencia no lineal . . . 12
3.3. Entropía de Transferencia . . . 13

4. Hipótesis **16**

5. Objetivos **16**
5.1. Objetivo General . . . 17
5.2. Objetivos Específicos . . . 17

6. Metodología **17**

7. Resultados Preliminares **19**
7.1. Correlación de Pearson y Correlación de distancis . . . 19
7.2. Resultados de la Entropía de Transferencia (TE) . . . 22

8. Cronograma **30**

9. Recursos **32**

1. Justificación y Planteamiento del Problema

1.1. Trabajo previo

El autor se desempeña como científico de datos en el equipo de ingeniería responsable del desarrollo y mantenimiento de plataformas de monitoreo geotécnico continuo de estructuras civiles. En el marco de este rol, ha participado en el desarrollo de varios sistemas de visualización y análisis de datos de instrumentación geotécnica, cuyo propósito es integrar y explorar las series temporales generadas por los distintos elementos de monitoreo instalados en los activos monitoreados. Esto ha implicado el tratamiento, procesamiento y análisis de datos provenientes de múltiples topologías de instrumentación, entre ellas el sistema EPM (*extensómetros de posición múltiple*) y el sistema MPT (*monitoreo del perfil de túnel*) que constituyen el objeto de estudio de esta investigación, así como otros sistemas de monitoreo adicionales. Esta experiencia operacional ha permitido al autor identificar, de forma directa, una limitación recurrente en la práctica del monitoreo geotécnico: la necesidad de disponer de series temporales completas para llevar a cabo análisis de comportamiento del macizo rocoso. En múltiples instancias, la ausencia de registros en alguno de los sistemas ha sido reconocida como un obstáculo para la interpretación integral del estado del túnel; sin embargo, hasta la fecha no se ha implementado ningún procedimiento formal que permita reconstruir dichas series de manera metodológicamente rigurosa ni cuantificar la incertidumbre asociada a los valores reconstituidos. La presente tesis nace directamente de esa necesidad identificada en el contexto operacional real, y propone un marco matemático para abordarla.

1.2. El problema

El túnel seleccionado como caso de estudio, es una infraestructura que conecta el complejo minero polimetálico más grande del mundo, ubicado en Perú, con las etapas de posprocesamiento del material crudo extraído. Este túnel, que contiene una cinta transportadora para mover el material, es monitoreado de forma continua mediante sistemas instrumentales que permiten observar su comportamiento mecánico a lo largo del tiempo, con el fin de detectar deformaciones anómalas y garantizar la seguridad operacional general.

Entre los sistemas de monitoreo instalados, dos resultan particularmente relevantes para esta investigación. El primero es el sistema de **Extensometría de Posición Múltiple (EPM)**, que mide deformaciones relativas del macizo rocoso mediante cuatro sensores instalados en ambas paredes del túnel. En cada perforación de aproximadamente diez metros de profundidad se instala un sensor anclado al fondo como punto de referencia fijo, y un segundo sensor a cinco metros de la pared del túnel. La interacción entre estos sensores permite medir la convergencia o divergencia de las paredes del

túnel en el tiempo. El sistema EPM genera cuatro series de tiempo sincronizadas de deformación, expresadas en milímetros, con una frecuencia de muestreo de **6 horas**.

El segundo sistema es el **Monitoreo de perfil del túnel (MPT**, que registra la evolución geométrica del perfil de la sección transversal del túnel mediante siete nodos de medición distribuidos en el perfil. Cada nodo registra mediciones de deformación e inclinación, generando en total **catorce series temporales por instante de tiempo** (siete mediciones de inclinación y siete de deformación), lo que permite estimar deformaciones relativas entre puntos y reconstruir la evolución del perfil del túnel.

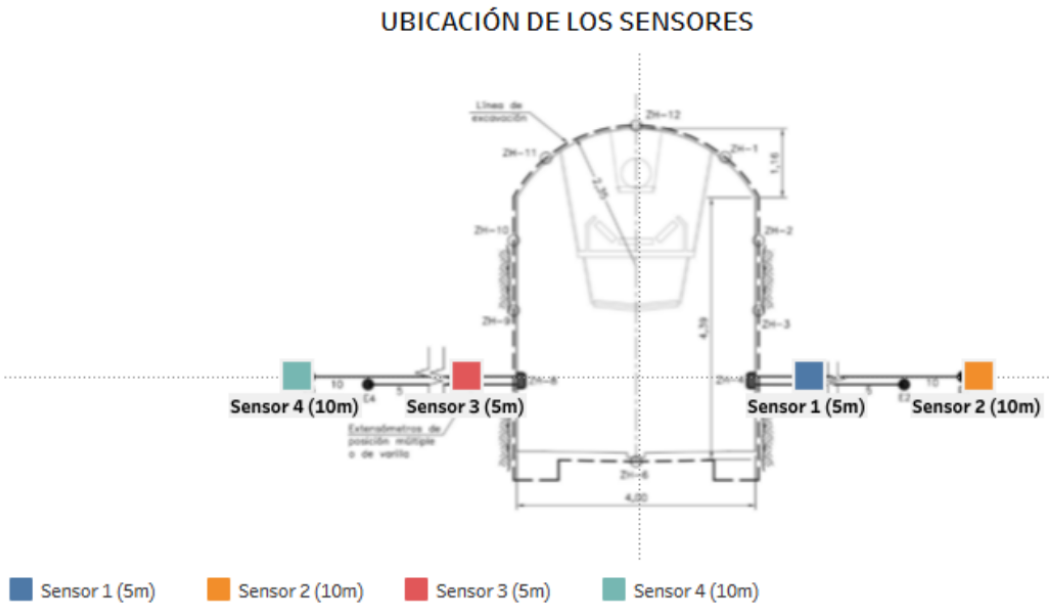


Figura 1: Esquema y ubicación de los sensores de deformación para el monitoreo por *Extensómetros de posición múltiple* (EPM)

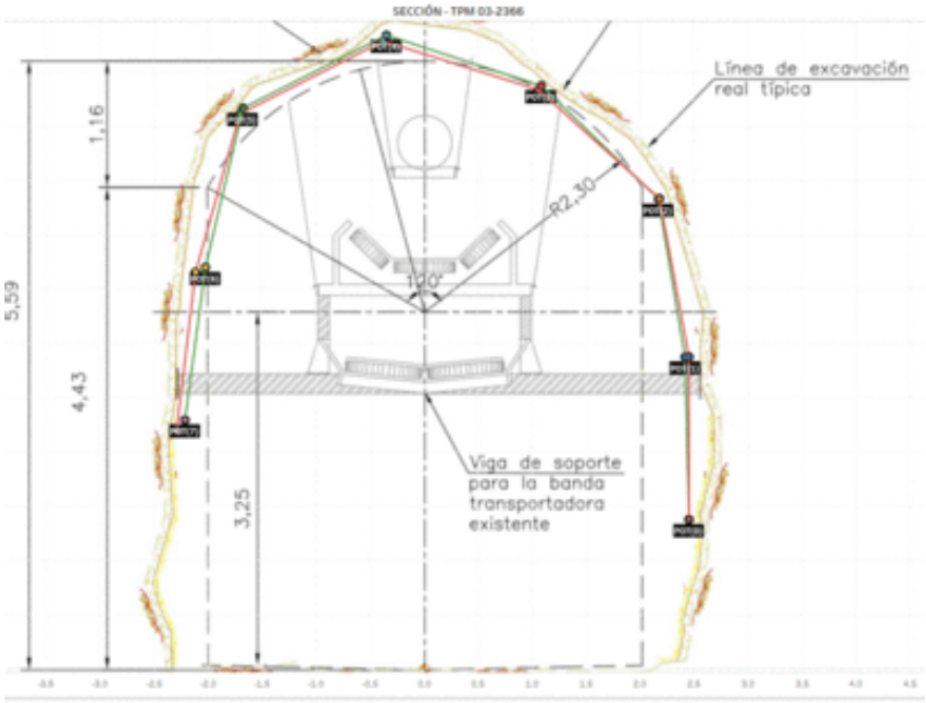


Figura 2: Esquema y ubicación de los sensores de deformación e inclinación para el monitoreo por *Monitoreo de perfil de túnel* (MPT)

El problema central de esta investigación es el siguiente: dentro de una ventana temporal de aproximadamente dos años de monitoreo, existe un período de **más de un año** en el cual el sistema EPM no registró datos, generando una pérdida significativa de información en las cuatro series temporales correspondientes. En contraposición, el sistema MPT sí cuenta con registros continuos durante ese período. Dado que ambos sistemas monitorean el comportamiento del mismo entorno geotécnico en una sección espacialmente cercana del túnel, se plantea la hipótesis de que existe una correlación estadísticamente significativa entre sus mediciones, incluso sabiendo que ambos representan distintas interpretaciones de la misma dinámica física del macizo rocoso.

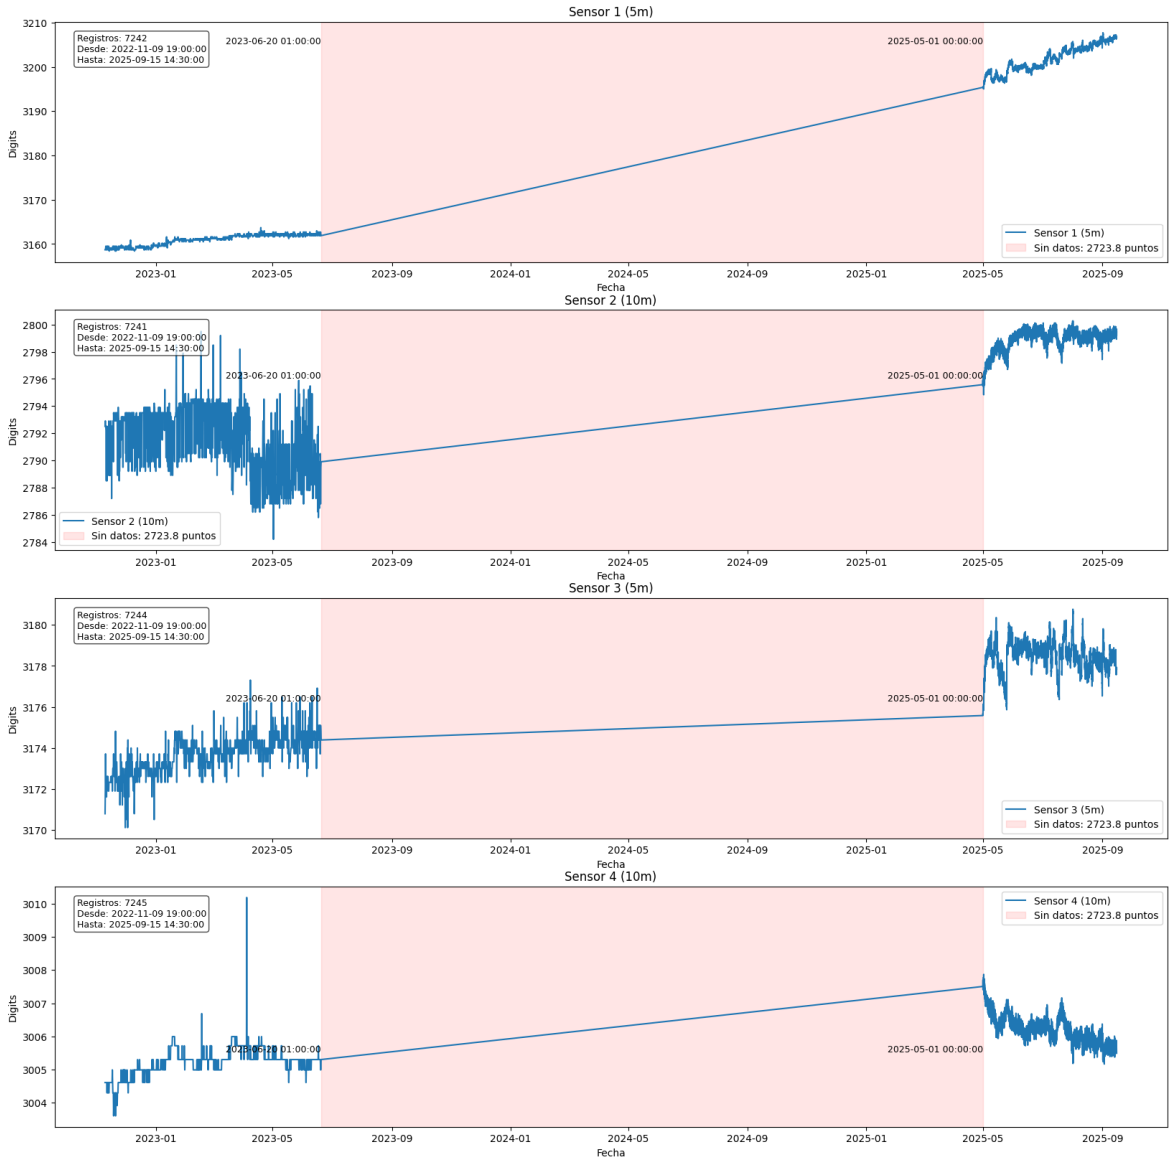


Figura 3: *Series temporales de los cuatro sensores EPM. La región sombreada indica el período de ausencia de registros (aproximadamente junio 2023 – mayo 2025). La línea continua dentro del período sin datos corresponde a una interpolación lineal ilustrativa entre el último y primer valor registrado, y no constituye una reconstrucción del modelo propuesto.*

Esta situación constituye un problema de **imputación de datos faltantes en series temporales multivariadas con fuente de información auxiliar**. Formalmente, si se denota el período observado como $[0, t_1] \cup [t_2, T]$ y el período faltante como $[t_1, t_2]$, el objetivo es estimar la distribución:

$$p\Big(\mathbf{y}_{\mathrm{EPM}}(t) \mid \mathbf{y}_{\mathrm{MPT}}(t),\ \mathbf{y}_{\mathrm{EPM}}^{\mathrm{obs}}\Big), \qquad t \in [t_1, t_2]. \tag{1}$$

La justificación de este problema es doble. Desde la perspectiva de la ingeniería geotécnica, reconstruir las series del EPM es indispensable para mantener la integridad histó-

rica del monitoreo, calibrar modelos de comportamiento del macizo rocoso y establecer criterios de alerta ante deformaciones anómalas. Desde la perspectiva matemática, el problema plantea un desafío no trivial: la reconstrucción no debe ser una interpolación arbitraria, sino un proceso de **inferencia bayesiana rigurosa** que preserve las propiedades dinámicas del fenómeno físico y cuantifique explícitamente la incertidumbre asociada a cada valor reconstruido.

1.3. Posibles aportes

Esta investigación tiene dos contribuciones concretas que se mueven entre lo matemático, lo metodológico y lo aplicado.

1.3.1. Aporte 1: un marco de reconstrucción que entiende la física del macizo

La contribución principal es desarrollar una forma de reconstruir series temporales faltantes en sistemas de monitoreo geotécnico que no sea una simple interpolación. La idea es usar Procesos Gaussianos de Salida Múltiple para hacer una inferencia bayesiana que tenga en cuenta cómo se comporta realmente el macizo rocoso. Lo que distingue este enfoque de otros es que la función que describe cómo se relacionan los dos sistemas de monitoreo no se escoge de forma arbitraria sino que se deriva directamente del modelo constitutivo de Nishihara, que es el modelo que describe la física de la fluencia de la roca. El posible resultado es una reconstrucción que es coherente con el comportamiento real del sistema y que además cuantifica explícitamente cuánta incertidumbre hay en cada valor reconstruido.

1.3.2. Aporte 2: usar un sensor para reconstruir otro

El segundo aporte tiene que ver con determinar mediante un modelo matemático si la información registrada por el MPT (*monitoreo del perfil del túnel*) puede usarse para reconstruir lo que el EPM (*extensómetro de posición múltiple*) no midió durante la brecha. Esto es posible porque ambos sistemas observan el mismo proceso físico subyacente, que es el campo de deformaciones del macizo rocoso, solo que desde perspectivas distintas. El marco propuesto, que sigue la formulación de [4] para modelos de múltiple fidelidad, provee la justificación matemática para hacer esa transferencia de información de manera rigurosa. Más allá del caso específico de este trabajo, el enfoque puede aplicarse a cualquier situación en geotecnia donde se tengan varios sistemas de monitoreo midiendo el mismo sistema físico y alguno de ellos presente datos incompletos.

2. Marco Teórico y Estado del Arte

2.1. El problema de datos faltantes en monitoreo estructural y geotécnico

El problema de datos faltantes en series temporales provenientes de sistemas de monitoreo es uno de los más frecuentes en aplicaciones de campo. En [3] distinguen dos patrones fundamentales de ausencia de datos. El primero corresponde al escenario *Missing At Random* (MAR), en el que los sensores fallan de forma ocasional y esporádica. El segundo, denominado *Missing Not At Random* (MNAR), corresponde a ausencias prolongadas y continuas causadas por fallas persistentes del sistema. El caso del sistema EPM en el túnel de la faja corresponde al patrón **MNAR**, con una interrupción superior a un año.

Los enfoques ad-hoc, como la interpolación lineal o el relleno por medias móviles, carecen de generalización y producen estimaciones sesgadas. Los métodos estadísticamente fundamentados, basados en inferencia bayesiana, son superiores en tanto incorporan la información observada y la incertidumbre derivada de los datos ausentes [7]. En este contexto, los Procesos Gaussianos han emergido como una herramienta especialmente adecuada para la imputación de series temporales, dado que proporcionan estimaciones puntuales junto con intervalos de confianza calibrados [3].

2.2. Procesos Gaussianos: fundamentos matemáticos

Definición 2.1 (Proceso Gaussiano)**.** *Un* ***Proceso Gaussiano*** *(GP) es un proceso estocástico* $\{f(t)\}_{t\in\mathcal{T}}$ *tal que para cualquier colección finita de instantes* $\{t_1, t_2, \ldots, t_n\} \subset \mathcal{T}$*, el vector aleatorio* $\mathbf{f} = (f(t_1), \ldots, f(t_n))^\top$ *sigue una distribución normal multivariada. Se escribe:*

$$f \sim \mathcal{GP}(m(\cdot),\, k(\cdot,\cdot))\,, \tag{2}$$

donde $m(t) = \mathbb{E}[f(t)]$ *es la* función de media *y* $k(t,t') = \mathbb{E}[(f(t)-m(t))(f(t')-m(t'))]$ *es la* función de covarianza *o* kernel*.*

El GP puede interpretarse como una distribución de probabilidad sobre el espacio de funciones: en lugar de buscar una única función que explique los datos, mantiene una familia completa de funciones posibles ponderadas por su plausibilidad ante la evidencia observada [10].

Cuando se dispone de observaciones ruidosas $y_i = f(t_i) + \varepsilon_i$ con $\varepsilon_i \sim \mathcal{N}(0, \sigma_n^2)$, el teorema central del GP establece que la distribución posterior sobre los valores no observados $\mathbf{f}_*$ es también gaussiana y tiene forma cerrada:

$$\mathbf{f}_* \mid \mathbf{y} \;\sim\; \mathcal{N}(\boldsymbol{\mu}_*,\, \boldsymbol{\Sigma}_*), \tag{3}$$

con media y covarianza posteriores dadas por:

$$\boldsymbol{\mu}_* = \mathbf{K}_{*\text{obs}} \left(\mathbf{K}_{\text{obs,obs}} + \sigma_n^2 \mathbf{I} \right)^{-1} \mathbf{y}, \tag{4}$$

$$\boldsymbol{\Sigma}_* = \mathbf{K}_{**} - \mathbf{K}_{*\text{obs}} \left(\mathbf{K}_{\text{obs,obs}} + \sigma_n^2 \mathbf{I} \right)^{-1} \mathbf{K}_{\text{obs}*}, \tag{5}$$

donde $\mathbf{K}_{\text{obs,obs}}$ es la matriz de covarianzas entre los instantes observados, $\mathbf{K}_{*\text{obs}}$ es la matriz de covarianzas entre los instantes a predecir y los observados, y $\mathbf{K}_{**}$ es la matriz de covarianzas entre los instantes a predecir entre sí. El vector $\boldsymbol{\mu}_*$ proporciona la reconstrucción puntual de las series faltantes, mientras que la diagonal de $\boldsymbol{\Sigma}_*$ cuantifica la incertidumbre instante por instante.

2.2.1. Funciones de covarianza relevantes

La elección del kernel $k(t, t')$ codifica los supuestos sobre la dinámica del sistema. Los kernels más relevantes [10] para el problema son :

- **Squared Exponential (SE):**

$$k_{\text{SE}}(t, t') = \sigma^2 \exp\left(-\frac{(t - t')^2}{2\ell^2} \right), \tag{6}$$

  donde σ^2 es la varianza y ℓ es la longitud de correlación. Produce funciones infinitamente diferenciables. En este trabajo se usará este kernel como punto de partida debido a su simplicidad y generalidad.

- **Matérn $\nu = 3/2$:**

$$k_{\text{M32}}(t, t') = \sigma^2 \left(1 + \frac{\sqrt{3}\,|t - t'|}{\ell} \right) \exp\left(-\frac{\sqrt{3}\,|t - t'|}{\ell} \right). \tag{7}$$

  Produce funciones con exactamente una derivada continua; más adecuado para señales geotécnicas con irregularidades locales.

- **Kernel periódico:**

$$k_{\text{per}}(t, t') = \sigma^2 \exp\left(-\frac{2 \sin^2(\pi |t - t'|/p)}{\ell^2} \right), \tag{8}$$

  con período p. Captura componentes cíclicas en las series de deformación.

Los kernels pueden combinarse aditivamente para capturar fenómenos simultáneos:

$$k(t, t') = k_{\text{SE}}(t, t') + k_{\text{per}}(t, t'), \tag{9}$$

modelando tendencia de largo plazo más componente cíclica operacional.

La estimación de los hiperparámetros $\boldsymbol{\theta} = \{\sigma^2, \ell, \sigma_n^2, \ldots\}$ se realiza maximizando la

log-verosimilitud marginal:

$$\log p(\mathbf{y} \mid \boldsymbol{\theta}) = -\tfrac{1}{2}\,\mathbf{y}^\top \mathbf{C}^{-1}\mathbf{y} - \tfrac{1}{2}\log|\mathbf{C}| - \tfrac{N}{2}\log(2\pi), \tag{10}$$

donde $\mathbf{C} = \mathbf{K}_{\text{obs,obs}} + \sigma_n^2\mathbf{I}$.

2.3. Proceso Gaussiano Multivariado de salida múltiple

El problema requiere extender el GP al caso multivariado, dado que se tienen 14 series del MPT y 4 series del EPM, todas correlacionadas. Se modela el sistema conjunto como un **Proceso Gaussiano de Salida Múltiple** (Multi-Output GP, MOGP):

$$\mathbf{f}(t) = \begin{pmatrix} \mathbf{f}_{\text{MPT}}(t) \\ \mathbf{f}_{\text{EPM}}(t) \end{pmatrix} \sim \mathcal{GP}(\mathbf{m}(\cdot),\, \mathbf{K}(\cdot,\cdot))\,, \tag{11}$$

donde $\mathbf{K}(t,t')$ es una matriz de kernels de dimensión 18×18 con estructura de bloques:

$$\mathbf{K}(t,t') = \begin{pmatrix} \mathbf{K}_{\text{MM}}(t,t') & \mathbf{K}_{\text{ME}}(t,t') \\ \mathbf{K}_{\text{EM}}(t,t') & \mathbf{K}_{\text{EE}}(t,t') \end{pmatrix}. \tag{12}$$

El bloque $\mathbf{K}_{\text{ME}}(t,t') \in \mathbb{R}^{14\times 4}$ es el *kernel cruzado* entre las series del MPT y del EPM, evaluado en dos instantes arbitrarios $t, t' \in [0,T]$. Cada entrada (i,j) de este bloque cuantifica la covarianza entre la serie del nodo MPT i en el instante t y la serie del sensor EPM j en el instante t'. El diseño de este bloque constituye la contribución matemática central de la tesis, pues se deriva analíticamente desde el operador diferencial del modelo constitutivo de Nishihara en lugar de adoptarse de forma arbitraria.

El bloque $\mathbf{K}_{\text{EM}}(t,t') \in \mathbb{R}^{4\times 14}$ satisface la relación $\mathbf{K}_{\text{EM}}(t,t') = \mathbf{K}_{\text{ME}}(t',t)^\top$ y no aporta información adicional, pero es necesario para garantizar la simetría de la matriz de covarianza completa $\mathbf{K}(t,t')$.

El bloque $\mathbf{K}_{\text{MM}}(t,t') \in \mathbb{R}^{14\times 14}$ contiene la covarianza entre los nodos del sistema MPT: su entrada (i,j) cuantifica la covarianza entre la serie del nodo MPT i en el instante t y la serie del nodo MPT j en el instante t'. Análogamente, el bloque $\mathbf{K}_{\text{EE}}(t,t') \in \mathbb{R}^{4\times 4}$ contiene la covarianza entre los sensores del sistema EPM: su entrada (i,j) cuantifica la covarianza entre el sensor EPM i en el instante t y el sensor EPM j en el instante t'. Ambos bloques diagonales se modelan mediante kernels estándar de la literatura, reservando la derivación desde el modelo constitutivo para el bloque cruzado $\mathbf{K}_{\text{ME}}$.

Para que $\mathbf{K}(t,t')$ defina un GP válido, la matriz debe ser semidefinida positiva para cualquier colección finita de instantes [2].

2.4. Modelo constitutivo del macizo rocoso como restricción física

Ambos sistemas de monitoreo miden proyecciones distintas del mismo campo de deformaciones $\boldsymbol{\varepsilon}(t)$, generado por un campo de esfuerzos latente $\boldsymbol{\sigma}(t)$ a través de una ley constitutiva:

$$\boldsymbol{\varepsilon}(t) = \mathcal{C}[\boldsymbol{\sigma}](t). \tag{13}$$

En el contexto de un túnel en operación continua bajo carga sostenida, el comportamiento del macizo rocoso incluye una componente de **fluencia** (*creep*): la deformación aumenta en el tiempo bajo esfuerzo constante. El **modelo de Nishihara** es un modelo viscoelastoplástico que descompone la deformación total en componentes elástica, viscoelástica y viscoplástica:

$$\varepsilon_{\text{total}}(t) = \varepsilon_e + \varepsilon_{ve}(t) + \varepsilon_{vp}(t). \tag{14}$$

El uso del modelo de Nishihara en ingeniería de túneles está bien respaldado en la literatura reciente. En [19] lo aplican para predecir la deformación de convergencia del macizo rocoso en un túnel excavado en roca blanda, calibrando los parámetros del modelo directamente a partir de datos de monitoreo de campo y obteniendo una buena correspondencia entre los valores teóricos y los medidos. En la misma línea, en [20] desarrollan una versión mejorada del modelo e implementan su desarrollo secundario en FLAC3D, validándola contra curvas de asentamiento y convergencia registradas en un túnel de pizarra carbonosa, con errores menores al cinco por ciento respecto a los valores observados. Estos trabajos confirman que el modelo de Nishihara no solo describe cualitativamente el comportamiento reológico del macizo sino que sus parámetros pueden identificarse de forma confiable a partir de series temporales de deformación instrumentada, lo cual es relevante para la presente investigación dado que se dispone de registros continuos del sistema MPT durante el período de operación del túnel.

El modelo constitutivo de Nishihara permite representar la deformación dependiente del tiempo del macizo rocoso mediante una descomposición aditiva de la deformación total. En la ecuación

$$\varepsilon_{\text{total}}(t) = \varepsilon_e + \varepsilon_{ve}(t) + \varepsilon_{vp}(t),$$

El término $\varepsilon_{\text{total}}(t)$ corresponde a la deformación total observada en el macizo en el instante t, es decir, la respuesta acumulada que podría ser registrada por los sistemas de monitoreo geotécnico. La componente ε_e representa la deformación elástica instantánea, asociada a la respuesta inmediata de la roca dado un cambio de esfuerzo, esta parte se considera recuperable y no depende explícitamente del tiempo. Por otro lado, $\varepsilon_{ve}(t)$ describe la deformación viscoelástica, que evoluciona gradualmente bajo carga

sostenida y representa la fluencia retardada pero que se puede recuperar del material. Finalmente, $\varepsilon_{vp}(t)$ corresponde a la deformación viscoplástica, asociada a cambios permanentes e irreversibles en el macizo cuando el nivel de esfuerzo supera ciertos umbrales de resistencia. En conjunto, esta formulación permite separar la respuesta inmediata, la respuesta que se puede reveretir y la deformación permanente, lo cual esta bien para describir la evolución temporal de las deformaciones alrededor de un túnel sometido a condiciones de carga sostenida.

Como se describe anteriormente, el modelo de Nishihara ha sido usado en ingeniería de túneles para predecir la deformación futura del macizo a partir de mediciones de convergencia, ajustando sus parámetros a curvas observadas y proyectando el comportamiento esperado. Esta tesis propone un uso distinto del mismo modelo, en lugar de usarlo como predictor determinístico, se extrae su ecuación diferencial para construir la función de covarianza de un Proceso Gaussiano, lo que permite formular la reconstrucción de la brecha EPM como un problema de inferencia bayesiana que aprovecha la información auxiliar del MPT y cuantifica explícitamente la incertidumbre sobre los valores no observados.

3. Análisis Estadístico y Validación de la Hipótesis de Correlación

Antes de construir el modelo de reconstrucción, es indispensable mostrar estadísticamente que las series del MPT y del EPM están correlacionadas de forma suficientemente estructurada como para justificar la inferencia de unas a partir de las otras. Esta sección presenta el programa de análisis estadístico que se llevará a cabo sobre los períodos con datos simultáneos de ambos sistemas.

3.1. Medidas de correlación clásica

Se calculará la **correlación de Pearson** entre cada par de series temporales del MPT y del EPM. Dado un par de series $X = \{x_1, x_2, \ldots, x_N\}$ e $Y = \{y_1, y_2, \ldots, y_N\}$, cada una con N observaciones simultáneas, el coeficiente de Pearson se define como:

$$r_{XY} = \frac{\sum_{i=1}^{N}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{N}(x_i - \bar{x})^2 \cdot \sum_{i=1}^{N}(y_i - \bar{y})^2}}, \tag{15}$$

donde x_i e y_i son los valores registrados por cada sensor en el instante i, y $\bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i$

y $\bar{y} = \frac{1}{N}\sum_{i=1}^{N} y_i$ son sus respectivas medias muestrales. El numerador acumula el producto de las desviaciones simultáneas de cada serie respecto a su media: si ambas series tienden a alejarse juntas de su valor típico, el producto es positivo y r_{XY} se acerca a 1; si se alejan en direcciones opuestas, r_{XY} se acerca a -1; si no existe relación lineal, r_{XY} se acerca a 0. El denominador normaliza ese producto para que el resultado quede siempre en el intervalo $[-1, 1]$, independientemente de las unidades de medición de cada sensor. Dado que la relación entre el MPT y el EPM puede presentar componentes no lineales, se calculará también la **correlación de Spearman**, que aplica el mismo coeficiente no sobre los valores originales sino sobre sus rangos ordenados, resultando más robusta ante no linealidades suaves y valores atípicos.

Adicionalmente, se calculará la **función de correlación cruzada con rezago** (CCF), definida como:

$$\rho_{XY}(\tau) = \frac{\mathbb{E}[(X(t) - \mu_X)(Y(t+\tau) - \mu_Y)]}{\sigma_X \, \sigma_Y}, \tag{16}$$

donde $\mu_X = \mathbb{E}[X(t)]$ y $\mu_Y = \mathbb{E}[Y(t)]$ son las medias de cada serie, σ_X y σ_Y son sus desviaciones estándar, y τ es el *rezago temporal*, es decir, el desplazamiento en el tiempo con el que se compara una serie respecto a la otra. El símbolo $\mathbb{E}[\,\cdot\,]$ denota el valor esperado, que puede interpretarse como el promedio del producto de las desviaciones cuando se evalúa sobre todos los instantes disponibles. El valor de τ para el cual $\rho_{XY}(\tau)$ alcanza su máximo, denotado τ^*, indica el retardo temporal característico entre los dos sistemas de monitoreo y tiene interpretación geotécnica directa: refleja el tiempo que tarda una perturbación mecánica en el macizo en manifestarse primero en el MPT y luego en el EPM, o viceversa.

3.2. Medidas de dependencia no lineal

Dado el comportamiento elastoplástico del macizo rocoso, la relación entre MPT y EPM puede ser no lineal, lo que hace insuficiente a Pearson. Se aplicarán las siguientes medidas:

Distance Correlation (dCor): propuesta por [11], se define como:

$$\mathrm{dCor}(X, Y) = \frac{\mathrm{dCov}(X, Y)}{\sqrt{\mathrm{dVar}(X) \cdot \mathrm{dVar}(Y)}}, \tag{17}$$

donde $\mathrm{dCov}(X, Y)$ es la covarianza de distancias entre X e Y, y $\mathrm{dVar}(X)$, $\mathrm{dVar}(Y)$ son las varianzas de distancias de cada serie consigo misma, ambas construidas a partir de matrices de distancias por pares entre observaciones. Su propiedad fundamental es que $\mathrm{dCor}(X, Y) = 0$ si y solo si X e Y son estadísticamente independientes, sin importar si la relación entre ellas es lineal, monótona o de cualquier otra forma funcional. Esto la distingue de Pearson, que solo detecta dependencia lineal y puede valer cero incluso

cuando existe una relación no lineal fuerte.

3.3. Entropía de Transferencia

La **Entropía de Transferencia** (TE *Transfer Entropy* en inglés) fue introducida por [16] para responder una pregunta que la información mutua no puede responder ¿el pasado de X contiene información sobre el futuro de Y que no estaba ya en el propio pasado de Y? Si la respuesta es sí, hay evidencia de que X influye dinámicamente sobre Y y no solo que ambos covarían por alguna razón externa. La distinción importa en este trabajo porque tanto el MPT como el EPM responden al mismo macizo rocoso: que exista correlación entre ellos no implica automáticamente que el MPT sea una fuente útil para inferir el EPM, a menos que el pasado del MPT aporte información sobre el futuro del EPM más allá de lo que predice el EPM por sí solo.

Entropía de Shannon e información mutua. La construcción de la TE se apoya en conceptos de teoría de la información, el primero de los cuales es la entropía de Shannon.

Definición 3.1 (Entropía de Shannon)**.** *Sea I una variable aleatoria discreta con distribución de probabilidad $\{p(i)\}_{i\in\mathcal{I}}$ sobre un conjunto finito de estados $\mathcal{I}$. La* ***entropía de Shannon*** *de I se define como*

$$H_I \;=\; -\sum_{i\in\mathcal{I}} p(i)\,\log p(i), \tag{18}$$

donde el logaritmo puede tomarse en base 2 (resultado en bits*) o en base e (resultado en* nats*). H_I cuantifica la incertidumbre media sobre los estados de I: alcanza su máximo cuando todos los estados son equiprobables y vale cero cuando un estado ocurre con certeza.*

La medida natural de dependencia entre dos procesos I y J a partir de la entropía es la **información mutua**, que cuantifica la desviación de la distribución conjunta $p(i,j)$ respecto a la hipótesis de independencia $p(i)\,p(j)$ usando la divergencia de Kullback–Leibler:

$$M_{IJ} \;=\; \sum_{i,j} p(i,j)\,\log\frac{p(i,j)}{p(i)\,p(j)} \;=\; H_I + H_J - H_{IJ} \;\geq\; 0. \tag{19}$$

La información mutua vale cero si y solo si I y J son estadísticamente independientes, lo que la hace más general que la correlación de Pearson. Sin embargo, tiene dos limitaciones que en el contexto de series temporales resultan problemáticas. La primera es que es **simétrica**: $M_{IJ} = M_{JI}$, así que no contiene ninguna información sobre la dirección de la dependencia. La segunda, menos evidente pero igualmente importante, es que es una medida sobre distribuciones *estáticas* de probabilidad y no sobre la dinámica del proceso. Introducir un retardo temporal en una de las variables, $M_{IJ}(\tau) = \sum p(i_n, j_{n-\tau}) \log \frac{p(i_n,j_{n-\tau})}{p(i)p(j)}$, añade una noción temporal, pero no resuelve el problema de

fondo: esta versión con retardo sigue confundiendo el intercambio real de información con la correlación debida a historia común o a señales de entrada compartidas.

Estructura dinámica: cadenas de Markov y tasa de entropía. Para superar esa limitación, [16] propone trabajar con **probabilidades de transición** en lugar de distribuciones de probabilidad estáticas. El punto de partida es modelar la serie temporal $\{I_n\}_{n\geq 0}$ como un proceso de Markov estacionario de orden k, es decir, aquel en que la probabilidad del estado en $n+1$ depende únicamente de los k estados más recientes:

$$p(i_{n+1} \mid i_n, \ldots, i_{n-k+1}) \;=\; p(i_{n+1} \mid i_n, \ldots, i_{n-k}) \,. \tag{20}$$

Se usa la notación compacta $i_n^{(k)} = (i_n,\, i_{n-1}, \ldots,\, i_{n-k+1})$ para el **vector de historia de orden** k, que agrupa los k valores más recientes del proceso hasta el instante n.

Definición 3.2 (Tasa de entropía)**.** *La **tasa de entropía** de un proceso de Markov de orden k es la incertidumbre media sobre el próximo estado, dado el conocimiento de la historia:*

$$h_I \;=\; -\sum_{i_{n+1},\, i_n^{(k)}} p\Big(i_{n+1},\; i_n^{(k)}\Big) \log p\Big(i_{n+1} \mid i_n^{(k)}\Big) \,. \tag{21}$$

Equivalentemente, $h_I = H_{I^{(k+1)}} - H_{I^{(k)}}$, donde $H_{I^{(m)}}$ denota la entropía de Shannon del vector de historia de longitud m.

A diferencia de H_I, que mide la incertidumbre sobre los estados de I sin considerar su orden temporal, la tasa de entropía h_I es una propiedad de la *dinámica* del proceso: captura cuánta incertidumbre residual queda sobre el futuro de I una vez que se conoce su propio pasado.

Derivación formal de la Entropía de Transferencia. Con la tasa de entropía como punto de referencia, la pregunta que da origen a la TE es la siguiente: ¿cuánto disminuye la incertidumbre sobre el futuro de I si, además de conocer su propio pasado, se conoce también el pasado de J? Antes de responderla, es necesario formalizar qué significa que J no transfiera información a I.

Definición 3.3 (Propiedad de Markov generalizada)**.** *Se dice que el proceso J **no transfiere información** al proceso I si*

$$p\Big(i_{n+1} \mid i_n^{(k)}\Big) \;=\; p\Big(i_{n+1} \mid i_n^{(k)},\; j_n^{(l)}\Big) \,, \tag{22}$$

es decir, si conocer la historia de orden l del proceso J no modifica la distribución de transición de I.

Cuando (22) se cumple, el proceso J es irrelevante para predecir el futuro de I, dado su propio pasado. La TE mide cuánto se viola esa igualdad: es la divergencia de Kullback–Leibler entre la distribución de transición de I cuando se conoce el pasado de J y la que resulta cuando no se lo conoce.

Definición 3.4 (Entropía de Transferencia [16])**.** *Sean $\{I_n\}$ y $\{J_n\}$ dos procesos estocásticos estacionarios, con vectores de historia de órdenes k y l respectivamente. La* ***Entropía de Transferencia de J hacia I*** *se define como*

$$T_{J\to I} \;=\; \sum_{i_{n+1},\, i_n^{(k)},\, j_n^{(l)}} p\Big(i_{n+1},\; i_n^{(k)},\; j_n^{(l)}\Big) \log \frac{p\Big(i_{n+1} \mid i_n^{(k)},\; j_n^{(l)}\Big)}{p\Big(i_{n+1} \mid i_n^{(k)}\Big)}. \tag{23}$$

La expresión (23) tiene una forma equivalente que resulta más directa de interpretar. Aplicando la regla de la cadena de la entropía condicional, $H(A,B) = H(B) + H(A|B)$, a los términos de la sumatoria, se obtiene que

$$T_{J\to I} \;=\; H\Big(I_{n+1} \mid I_n^{(k)}\Big) \;-\; H\Big(I_{n+1} \mid I_n^{(k)},\; J_n^{(l)}\Big)\,, \tag{24}$$

donde $H(A \mid B) = -\sum_{a,b} p(a,b) \log p(a \mid b)$ es la entropía condicional de Shannon. El primer término es la incertidumbre sobre el estado futuro de I conociendo solo su historia; el segundo es la incertidumbre que queda al incorporar también la historia de J. La diferencia es positiva cuando el pasado de J efectivamente reduce la incertidumbre sobre el futuro de I, y vale exactamente cero cuando la igualdad (22) se satisface.

Proposición 3.1 (Propiedades fundamentales [16])**.** *La Entropía de Transferencia satisface las siguientes propiedades:*

(I) ***No negatividad:*** *$T_{J\to I} \geq 0$, con igualdad si y solo si se cumple (22). Esta propiedad se hereda directamente de la no negatividad de la divergencia de Kullback–Leibler.*

(II) ***Asimetría:*** *en general $T_{J\to I} \neq T_{I\to J}$, lo que permite establecer cuál de los dos sistemas lidera al otro en términos de flujo de información.*

(III) ***Exclusión de historia común:*** *al condicionar sobre $i_n^{(k)}$ en (23), se descuenta la información que I ya tiene sobre su propio futuro. Así, la TE captura solo el intercambio dinámico entre I y J, no la correlación estática que ambos puedan tener por responder al mismo driver externo.*

(IV) ***Independencia de la resolución en el caso continuo:*** *para acoplamientos no deterministas, $\lim_{\varepsilon\to 0} T_{Y\to X}(\varepsilon)$ es finito e independiente de la partición empleada para discretizar los estados.*

Estimación e inferencia estadística. Las probabilidades $p(i_{n+1}, i_n^{(k)}, j_n^{(l)})$ en (23) no son conocidas y deben estimarse desde los datos. Para ello se usa el **estimador de histograma** de [18]: cada serie se discretiza en B intervalos de igual amplitud sobre su rango empírico y las probabilidades de transición se aproximan por frecuencias relativas. [18] recomiendan $B \in \{4,5,6\}$ intervalos para series de longitud $N \in [500, 2000]$, rango en el que se controla razonablemente el compromiso entre sesgo y varianza del estimador. En este trabajo se usan $B = 5$ intervalos y órdenes $k = l = 1$.

Que el valor estimado de $T_{J\to I}$ sea positivo no implica por sí solo que haya flujo real de información: siempre existe una componente de sesgo de estimación. Por eso se evalúa la significancia estadística mediante el **test de datos sustitutos** de [17]: se generan N_s permutaciones aleatorias de la serie J que destruyen sus dependencias temporales pero preservan su distribución marginal de valores, y se calcula $T_{J\to I}$ en cada permutación para construir la distribución de referencia bajo la hipótesis nula $\mathcal{H}_0$ de ausencia de flujo de información. Se rechaza $\mathcal{H}_0$ al nivel $\alpha = 0.05$ cuando el valor observado supera el percentil 95 de esa distribución. En este trabajo se usan $N_s = 199$ permutaciones, que es el número mínimo para garantizar resolución exacta al nivel $\alpha = 0.05$ con un test de permutación.

Aplicación al sistema MPT–EPM.

Observación 3.1. *En el contexto de esta investigación, la TE se calcula tomando como proceso fuente J a cada serie del sistema MPT y como proceso objetivo I a cada serie del EPM. Un valor $T_{\mathrm{MPT}\to\mathrm{EPM}} > 0$ estadísticamente significativo indica que la historia reciente del MPT reduce la incertidumbre sobre el comportamiento futuro del EPM más allá de lo que predice su propio pasado, en otras palabras, que el MPT contiene información dinámica sobre el EPM que no se explica por la autocorrelación de este último. La asimetría de la medida permite además verificar si la dirección dominante del flujo es efectivamente* $\mathrm{MPT}\to\mathrm{EPM}$ *o si el EPM también lidera al MPT de forma comparable. Desde el punto de vista del modelo propuesto, estos resultados son la justificación estadística del rol asimétrico que se le asigna al MPT como fuente auxiliar en el MOGP: si el flujo neto de información fuese nulo, incorporar el MPT en la estructura de covarianza cruzada no aportaría capacidad predictiva adicional sobre la brecha del EPM.*

4. Hipótesis

Existe una estructura de covarianza cruzada entre las series del sistema MPT y las series del sistema EPM, derivable del modelo constitutivo viscoelástico del macizo rocoso (Nishihara), que permite la inferencia bayesiana de los datos EPM faltantes con incertidumbre cuantificable, mediante un Proceso Gaussiano Multivariado de salida múltiple con kernel informado por física.

5. Objetivos

5.1. Objetivo General

Desarrollar un marco matemático basado en Procesos Gaussianos Multivariados con kernel informado por un modelo constitutivo de roca para la reconstrucción de series temporales geotécnicas faltantes, con cuantificación de incertidumbre, aplicado al caso de estudio.

5.2. Objetivos Específicos

OE1. Mostrar estadísticamente, mediante una batería jerárquica de pruebas de dependencia lineal, no lineal y estructural, si las series del MPT contienen información estadísticamente significativa sobre las series del EPM, para validar así la hipótesis central de la tesis.

OE2. Derivar analíticamente el kernel cruzado entre los sistemas MPT y EPM a partir del operador diferencial lineal de un modelo constitutivo del macizo rocoso, inicialmente el modelo de Nishihara, sujeto a revisión según los datos, siguiendo el marco de Raissi et al. [9].

OE3. Implementar un modelo MOGP que permita la imputación de las series faltantes temporales del EPM a partir del Kernel informado por la física y los datos del sistema de monitoreo MPT.

OE4. Evaluar el aporte de cada componente del modelo mediante un estudio de ablación progresivo, evaluando el efecto incremental de incorporar la fuente auxiliar MPT y la restricción física del modelo constitutivo sobre la calidad de la reconstrucción.

6. Metodología

El desarrollo de la tesis se organiza en cinco bloques de trabajo, cada uno asociado directamente a un objetivo específico.

OE1 — Mostrar estadísticamente la dependencia MPT→EPM

- Limpiar y alinear temporalmente las 18 series: detectar valores atípicos, corregir desfases de muestreo y documentar el período de observación simultánea que se usará en todos los análisis posteriores.
- Calcular las correlaciones de Pearson, Spearman y la función de correlación cruzada con rezago entre cada par MPT-EPM, identificando el rezago óptimo τ^* y su interpretación geotécnica.
- Calcular Distance Correlation, Información Mutua y Transfer Entropy para cap-

turar dependencias no lineales y establecer la direccionalidad MPT→EPM del flujo de información.

OE2 — Derivar el kernel de Nishihara, formular el MOGP y demostrar validez

- Escribir el operador diferencial lineal de la rama elástica y viscoelástica del modelo de Nishihara, calcular su función de Green y verificar que cumple las condiciones del marco teórico de Raissi et al. [9].
- Aplicar el operador al kernel base para obtener los tres bloques del MOGP —k_{EE}, k_{TE} y k_{TT}— todos en forma cerrada como función de t, t' y los parámetros físicos $\{E_0, E_1, \eta_1\}$.
- Demostrar formalmente que la matriz $\mathbf{K}(t, t') \in \mathbb{R}^{18\times 18}$ es semidefinida positiva, siguiendo la construcción por convolución de procesos de Álvarez et al. [2].
- Verificar numéricamente la semidefinición positiva evaluando el kernel en puntos de prueba y comprobando que todos los valores propios de la matriz de Gram resultante son no negativos.

OE3 — Implementar el MOGP y estimar parámetros

- Explorar las librerías `GPflow` y `GPyTorch` con una versión simplificada del problema y del kernel, para reconocer el alcance, bondades y marco de implementación de cada una.
- Definir e implementar el esquema de ajuste de hiperparámetros a partir de la log-verosimilitud marginal para el problema simplificado.
- Implementar programaticamente la función de covarianza o Kernel con las características fisica definidas por el modelo constitutivo seleccionado.
- Extender la implementación del esquema de ajuste de hiperparámetros a partir de la log-verosimilitud marginal, para obtener las constante del modelo físico, y de ser posible, comparar con las propiedades mecánicas reportadas para el macizo a partir de los ensayos geotécnicos existentes.
- Generar la reconstrucción de las cuatro series EPM en $[t_1, t_2]$, produciendo para cada instante la media posterior y los intervalos de credibilidad.
- Diseñar el experimento de validación cruzada ocultando artificialmente ventanas de distinta duración —una semana, un mes y tres meses— en los períodos observados, para evaluar cómo degrada el modelo con brechas más largas.
- Calcular RMSE, MAE y demás métricas para el escenario de validación.

OE4 — Estudio de ablación progresivo

- Entrenar y evaluar un GP univariado por canal EPM sin información del MPT, para establecer el piso de comparación.
- Entrenar y evaluar el MOGP con kernel libre estándar y MPT como fuente auxiliar, para cuantificar el aporte del MPT con independencia del kernel físico.
- Entrenar y evaluar el MOGP completo con kernel de Nishihara, para cuantificar el aporte adicional de la restricción física sobre el MOGP con kernel libre.
- Consolidar las métricas de las tres configuraciones en una tabla comparativa e interpretar los resultados en términos geotécnicos.

7. Resultados Preliminares

7.1. Correlación de Pearson y Correlación de distancis

Como exploración inicial de la hipótesis central de la tesis, se han calculado medidas de correlación entre las series del sistema MPT y del sistema EPM durante los períodos con datos simultáneos.

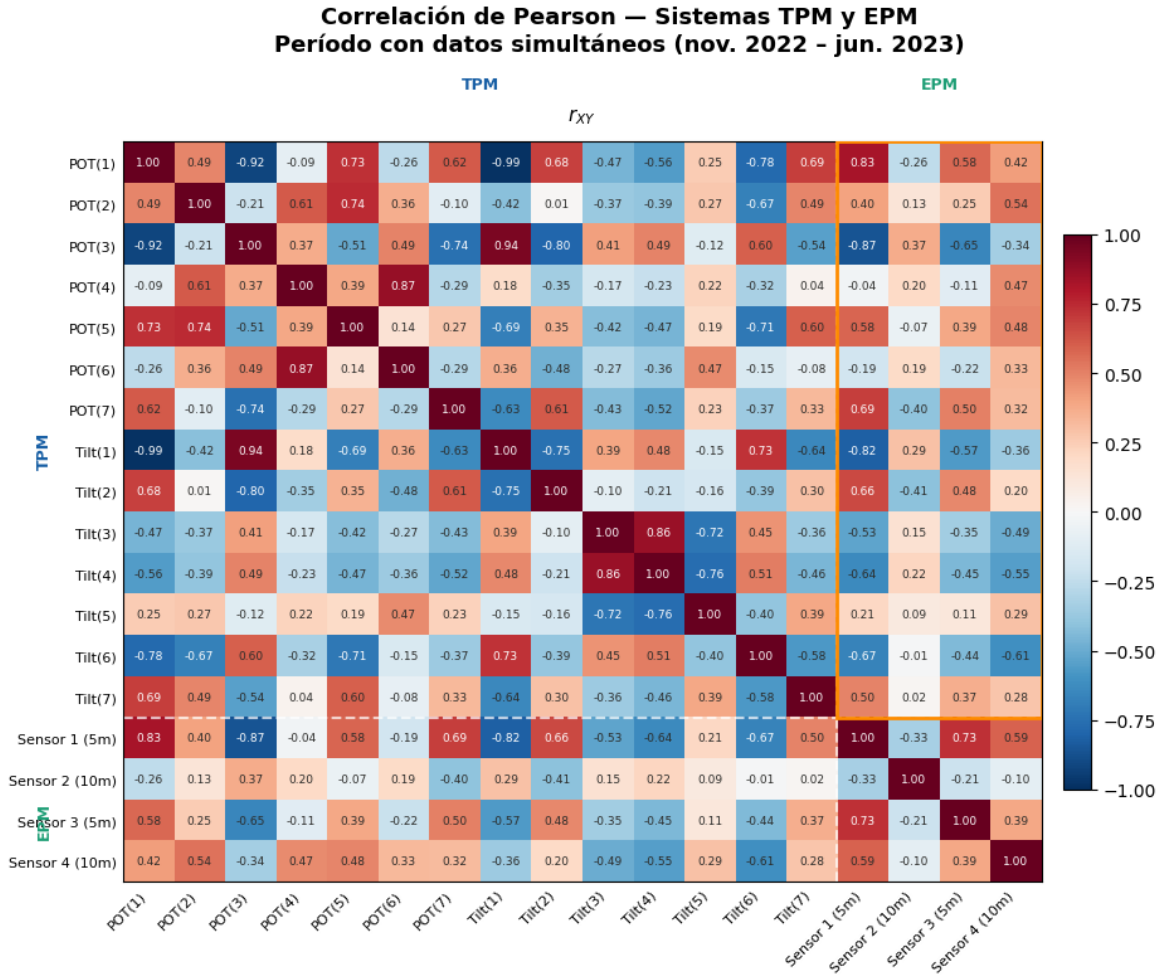


Figura 4: Matriz de correlación de Pearson entre las 18 series del sistema de monitoreo geotécnico (14 series MPT y 4 series EPM) durante el período de observación simultánea (noviembre 2022 – junio 2023). Los valores en el bloque cruzado MPT–EPM, delimitado en naranja, evidencian la existencia de correlación lineal entre ambos sistemas. Los valores negativos en ese bloque reflejan que algunos pares de sensores miden proyecciones opuestas del mismo campo de deformaciones, no ausencia de relación.

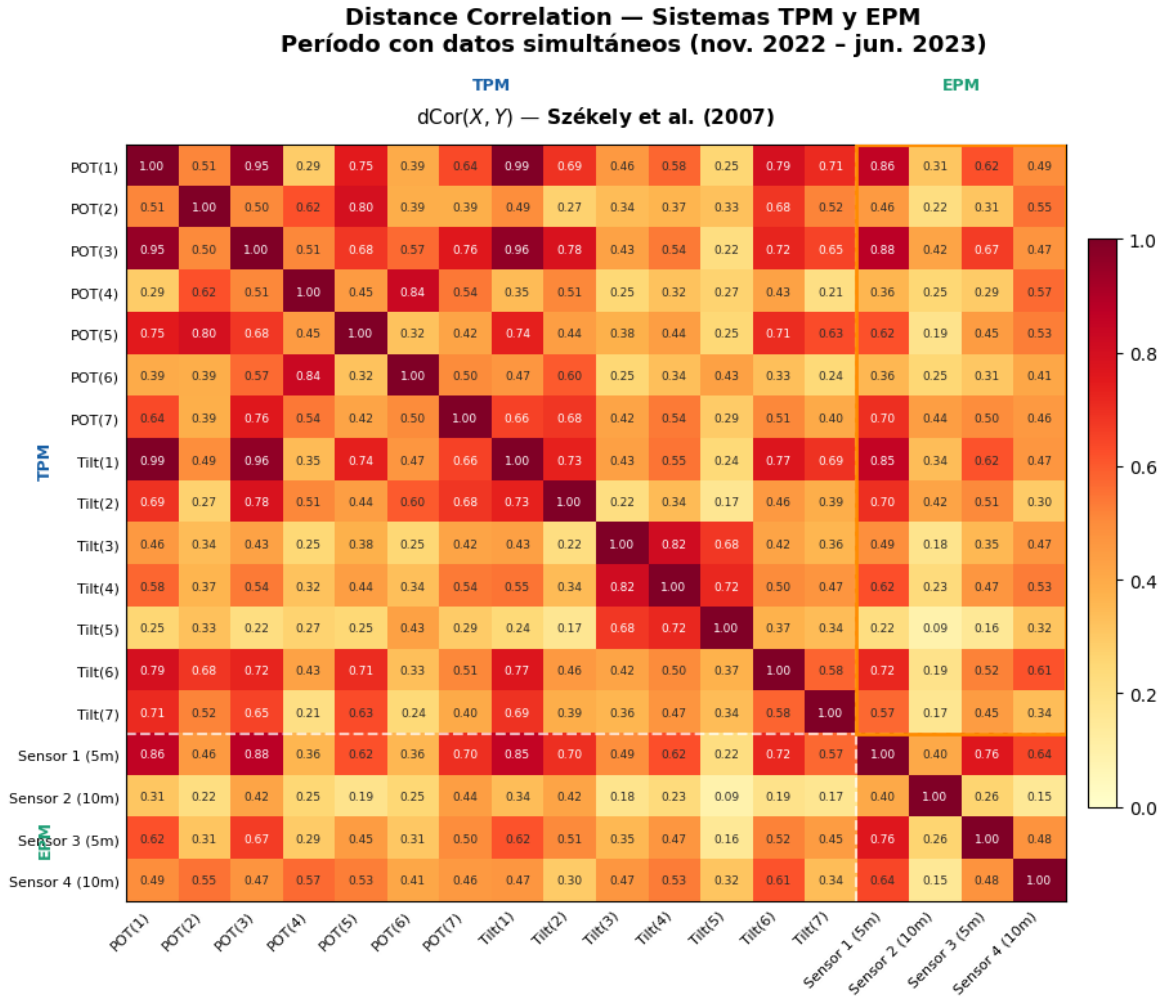


Figura 5: Matriz de Distance Correlation entre las 14 series del MPT y las 4 series del EPM durante el período con datos simultáneos (noviembre 2022 – junio 2023). Esta tiene la ventaja sobre pearson de que detecta cualquier tipo de relación entre variables, no solo las lineales, y solo vale cero cuando dos series son completamente independientes. El bloque cruzado MPT–EPM, resaltado en naranja, muestra que que la gran mayoría de pares presentan valores alejados de cero, lo que indica que los dos sistemas comparten información sobre la dinámica del macizo rocoso incluso en sensores donde Pearson no detectaba relación aparente.

Al revisar la matriz de correlación de Pearson, lo primero que llama la atención es que dentro del bloque del MPT hay varios valores negativos, especialmente entre los sensores POT y los Tilt. Esto en principio puede parecer raro, pero tiene sentido si se considera que los POT miden desplazamiento y los Tilt miden inclinación: cuando el macizo se mueve en un sentido, los dos tipos de sensor responden en sentidos contrarios. El signo negativo, entonces, no indica que no haya relación entre esos sensores, sino que están midiendo aspectos distintos del mismo movimiento.

En el bloque cruzado entre MPT y EPM, el Sensor 1 (5m) es el que aparece con las correlaciones más altas. Con POT(1) alcanza $r = 0.83$ y con POT(3) llega a $r = -0.87$, ambos valores altos en magnitud. El Sensor 2 (10m), en cambio, presenta correlaciones

notablemente más bajas que el resto de los sensores EPM. No es claro todavía si esto se debe a que ese punto del macizo tiene un comportamiento mecánico diferente o simplemente a que tiene más ruido en sus registros; eso es algo que vale la pena investigar con más detalle en la etapa de análisis más profundo.

Al pasar a la *Distance Correlation* el panorama se aclara bastante. Esta medida tiene la propiedad de que es cero únicamente cuando dos variables son completamente independientes, sin importar si la relación entre ellas es lineal o no. En el bloque cruzado MPT–EPM prácticamente todos los pares muestran valores por encima de 0.3. Lo más interesante es lo que ocurre con los sensores Tilt: Pearson les asignaba correlaciones bajas o negativas con el EPM, lo que podría llevar a pensar que no hay ninguna relación. Pero la *Distance Correlation* muestra valores entre 0.3 y 0.7 en esos mismos pares, lo que indica que sí existe dependencia entre esos sensores, solo que no es de tipo lineal y por eso Pearson no la estaba capturando.

En conjunto, los dos análisis apuntan en la misma dirección: los sistemas MPT y EPM comparten información sobre la dinámica del macizo. Pearson lo captura donde la relación es más directa, y la *Distance Correlation* extiende esa evidencia a los pares donde la relación es más compleja. El hecho de que el bloque cruzado muestre valores consistentemente distintos de cero en casi todos los pares es suficiente para justificar la hipótesis de que el MPT puede aportar información útil para inferir las series del EPM durante el período sin datos.

7.2. Resultados de la Entropía de Transferencia (TE)

Se aplicó el test de datos sustitutos descrito en la Sección 3.3 con $N_s = 199$ permutaciones y nivel $\alpha = 0.05$, evaluando la TE en el rezago óptimo τ^* que maximiza $T_{\mathrm{MPT}\to\mathrm{EPM}}(\tau)$ para cada uno de los 56 pares de series MPT–EPM.

Flujo de información MPT → EPM. La Figura 6 muestra los valores de $T_{\mathrm{MPT}\to\mathrm{EPM}}(\tau^*)$ para los 56 pares. Los valores oscilan entre 0.026 y 0.158 bits, lo que representa una variación de casi seis veces entre el par con menor y mayor transferencia. Esta dispersión no es aleatoria: los valores altos y bajos no se reparten por igual en todas las filas y columnas del mapa de calor, sino que hay patrones claros que dependen de qué serie del MPT se considera y de qué sensor EPM recibe la información.

El patrón más claro que emerge es el de la serie **POT(3)**: es la fuente de mayor transferencia de información hacia el EPM en tres de los cuatro sensores, con valores de 0.108, 0.158 y 0.142 bits para S1, S2 y S3 respectivamente. En el otro extremo, el sensor **S4 (10m)** presenta los valores más bajos en prácticamente todas las columnas, con un rango de 0.026 a 0.063 bits. No queda claro todavía si esto refleja un comportamiento mecánico diferente debido a esa profundidad en el macizo o si simplemente hay mayor nivel de ruido en ese canal.

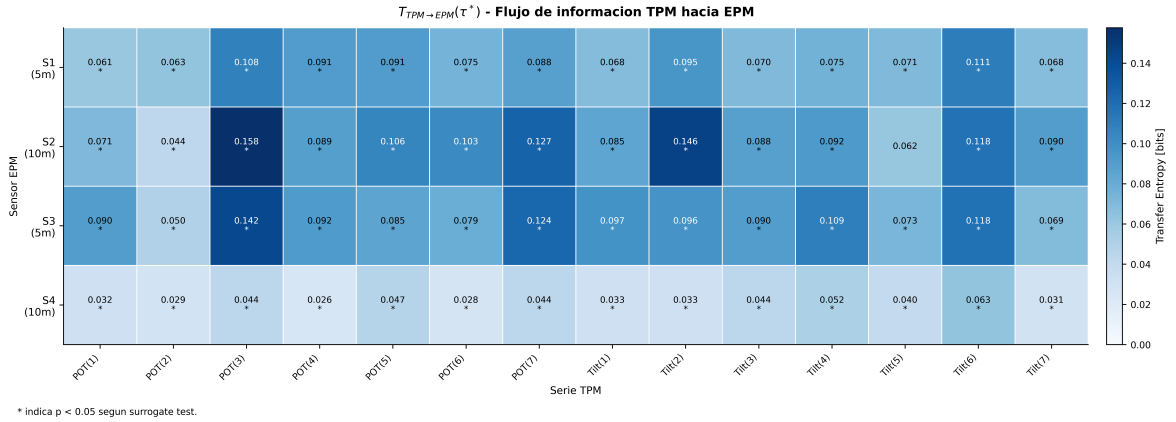


Figura 6: Entropía de Transferencia $T_{\mathrm{MPT}\to\mathrm{EPM}}(\tau^*)$ para los 56 pares de series del sistema de monitoreo durante el período con datos simultáneos (noviembre 2022– junio 2023). El asterisco (*) indica significancia estadística al nivel $\alpha = 0.05$ según el test de datos sustitutos con $N_s = 199$ permutaciones. Los valores se expresan en bits.

Otro rasgo que llama la atención es la serie **Tilt(2)**, que alcanza 0.146 bits hacia S2 y 0.096 hacia S3, valores comparables a los de POT(3) a pesar de que Tilt mide inclinación y no desplazamiento. Que un sensor de inclinación transfiera información significativa hacia los extensómetros podría sugerir que el campo de deformaciones del macizo que genera dichas inclinaciones en los puntos de medida del monitoreo MPT se pueden relacionar con los movimientos que generan las deformaciones laterales del macizo donde mide el monitoreo EPM.

Para cada uno de los 56 pares, el test de datos sustitutos produce un número llamado que llamaremos *p-valor* (para referenciarlo facilmente en los libros de python que corren estos cálculos), es la fracción de las 199 permutaciones aleatorias que lograron igualar o superar el valor de TE calculado con los datos reales en su orden temporal original. Un p-valor cercano a cero significa que prácticamente ninguna de las 199 versiones aleatorias de la serie fuente produjo una TE tan alta como la observada, lo que hace muy difícil atribuir ese resultado al azar. El umbral de decisión es $p < 0.05$: si menos del 5 % de las permutaciones igualaron o superaron el valor observado, se concluye que existe flujo de información estadísticamente significativo entre ese par de series. La Figura 7 muestra ese p-valor para cada uno de los 56 pares en la dirección MPT → EPM.

Los resultados muestran que 55 de los 56 pares presentan $p = 0.000$, lo que con $N_s = 199$ permutaciones significa que ninguna permutación alcanzó el valor observado de TE. El único par que no supera el umbral de significancia es **S2 (10m)–Tilt(5)**, con $p = 0.055$. Este resultado es coherente con el análisis de correlación previo, donde S2 (10m) mostró las correlaciones más débiles del bloque cruzado, y con el hecho de que ese par ya presentaba la magnitud de TE más baja de toda su fila (0.062 bits). Estos resultados en conjunto respaldan la hipótesis de que el flujo de información MPT → EPM es un fenómeno real y no un efecto propio del estimador.

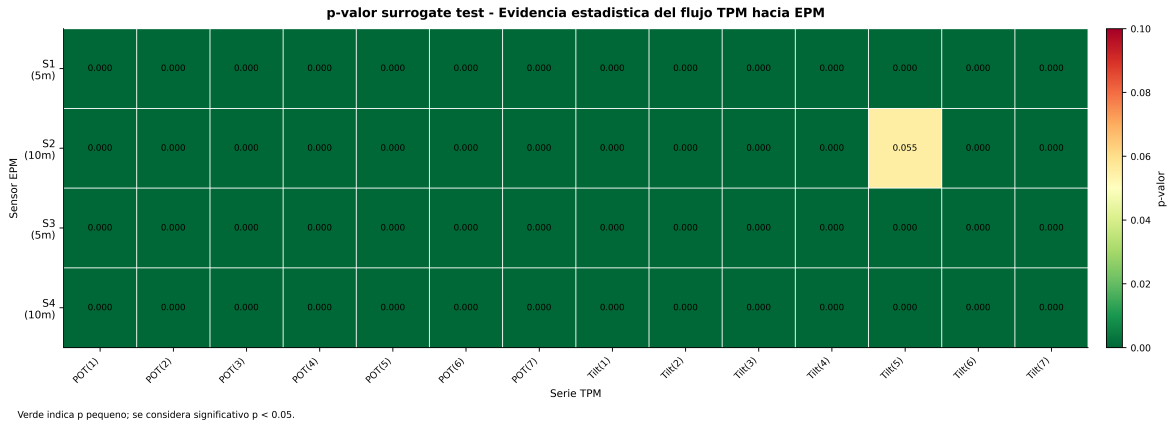


Figura 7: P-valores del test de datos sustitutos ($N_s = 199$ permutaciones) para la Entropía de Transferencia en la dirección MPT → EPM. Las celdas en verde oscuro corresponden a $p = 0{,}000$, indicando que ninguna de las 199 permutaciones igualó o superó el valor observado. La única celda con color claro corresponde al par S2 (10m)–Tilt(5), con $p = 0{,}055$.

Magnitud del acoplamiento MPT → EPM. Para contextualizar si los valores observados son grandes o pequeños en términos del sistema, se calculó una versión normalizada siguiendo a [21]. El procedimiento consiste en restar al valor observado T_{obs} el sesgo del estimador, aproximado por la media $\langle T_\pi \rangle$ de las 199 TE permutadas, y dividir el resultado entre la entropía condicional $H(X_{t+1} \mid X_t^{(k)})$ de cada sensor EPM. Esta última cuantifica la incertidumbre que el sensor tiene sobre su propio valor siguiente dado su historia reciente. La TE normalizada resultante responde la pregunta: ¿qué fracción de esa incertidumbre propia logra explicar el MPT?

$$\tilde{T}_{\text{MPT}\to\text{EPM}} = \frac{T_{\text{obs}} - \langle T_\pi \rangle}{H(X_{t+1} \mid X_t^{(k)})}, \tag{25}$$

donde $\langle T_\pi \rangle$ denota la media de las 199 TE calculadas sobre las permutaciones de la serie fuente.

Cuadro 1: Rango de TE normalizada en la dirección MPT → EPM para los pares estadísticamente significativos, siguiendo a [21]. $H(X_{t+1} \mid X_t^{(k)})$ es la incertidumbre propia de cada sensor sobre su siguiente valor. El techo teórico con $B = 5$ bins es $\log_2(5) \approx 2{,}32$ bits.

Sensor EPM	$H(X_{t+1} \mid X_t^{(k)})$ (bits)	Mínimo	Máximo	Media
Sensor 1 (5m)	1,17	3,03 %	6,63 %	4,39 %
Sensor 2 (10m)	2,08	0,79 %	4,93 %	2,61 %
Sensor 3 (5m)	1,77	1,68 %	5,56 %	3,28 %
Sensor 4 (10m)	0,69	2,07 %	7,45 %	4,14 %

Los porcentajes van de 0.79 % a 7.45 %. Antes de leer eso como "poco", vale la pena considerar la columna de $H(X_{t+1} \mid X_t^{(k)})$. El Sensor 4 (10m) tiene la entropía condicio-

nal más baja (0.69 bits), lo que indica que es el sensor más predecible desde su propio pasado. El Sensor 2 (10m) tiene 2.08 bits, casi en el techo teórico, lo que refleja que su comportamiento es bastante menos predecible. Un porcentaje alto en el Sensor 4 no significa que el MPT le aporte más información en términos absolutos, sino que ese aporte cubre una fracción mayor de lo que ese sensor no podía predecirse a sí mismo.

Los porcentajes del 1 % al 7 % son coherentes con lo que se esperaría físicamente. El MPT y el EPM no miden lo mismo, uno registra desplazamiento e inclinación del perfil del túnel, el otro mide convergencia de las paredes en profundidad. Los dos responden al mismo campo de esfuerzos del macizo pero desde ángulos distintos, y un acoplamiento cercano al 100 % solo tendría sentido si fueran el mismo sensor.

Dirección inversa: EPM → MPT. La Figura 8 muestra los valores máximos de $T_{\mathrm{EPM}\to\mathrm{MPT}}(\tau)$ sobre todos los rezagos evaluados.

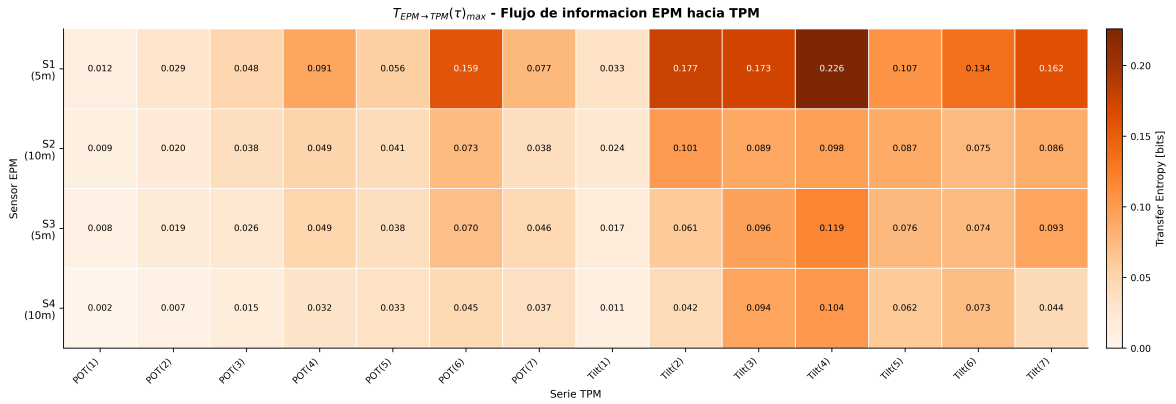


Figura 8: Entropía de Transferencia $T_{\mathrm{EPM}\to\mathrm{MPT}}(\tau)_{\mathrm{máx}}$ para los 56 pares de series. Los valores se expresan en bits. La significancia estadística en esta dirección se reporta en las Tablas 2 a 4, donde los pares se clasifican según el resultado del test de datos sustitutos en cada dirección.

A diferencia de la dirección MPT → EPM, donde la información transferida o identificada era mas fuerte desde las variables POT del monitoreo MPT hacia los sensores del monitoreo TPM, aquí hay una concentración notable en los sensores **Tilt**, el par S1 (5m)–Tilt(4) alcanza 0.226 bits, seguido de S1–Tilt(2) con 0.177 bits y S1–Tilt(3) con 0.173 bits. Los sensores POT, en cambio, presentan valores bajos en esta dirección, POT(1) y POT(2) están por debajo de 0.030 bits en todos los sensores EPM.

El test de datos sustitutos en la dirección EPM → MPT resultó significativo en 45 de los 56 pares ($p < 0.05$). Según la combinación de resultados en ambas direcciones, los 56 pares se distribuyen en tres categorías que se reportan en las tablas siguientes.

Observación 7.1. *La razón $R = T_{MPT\to EPM}/T_{EPM\to MPT}$ tiene interpretación causal directa únicamente en los pares donde ambas direcciones resultaron estadísticamente significativas (Tabla 2). En esos pares, $R < 1$ indica que $T_{EPM\to MPT} > T_{MPT\to EPM}$ con ambas magnitudes estadísticamente validadas, por lo que la dominancia del EPM en*

esos casos es un resultado real. En los pares donde solo la dirección MPT → EPM supera el umbral de significancia (Tabla 3), el denominador no está verificado y los valores elevados de R reflejan que el numerador es real mientras que el denominador es en buena parte ruido de estimación.

Cuadro 2: Pares MPT–EPM con flujo de información estadísticamente significativo en **ambas** direcciones ($p < 0.05$, test de datos sustitutos con $N_s = 199$ permutaciones, $\alpha = 0.05$). $T_{\mathrm{M}\to\mathrm{E}}$: TE en la dirección MPT → EPM evaluada en τ^* óptimo para esa dirección. $T_{\mathrm{E}\to\mathrm{M}}$: TE en la dirección EPM → MPT evaluada en su propio τ^* óptimo. $R = T_{\mathrm{M}\to\mathrm{E}}/T_{\mathrm{E}\to\mathrm{M}}$. La dirección MPT → EPM presenta $p = 0.000$ en todos los pares de esta tabla. **M → E**: el MPT transfiere más información al EPM. **E → M**: el EPM transfiere más información al MPT. ≈ sim.: $R \approx 1$.

Serie MPT	**Sensor EPM**	$T_{\mathrm{M}\to\mathrm{E}}$ [bits]	$T_{\mathrm{E}\to\mathrm{M}}$ [bits]	$p_{\mathrm{E}\to\mathrm{M}}$	R	**Dom.**
POT(2)	S1 (5m)	0,0631	0,0294	0,000	2,15	M → E
POT(2)	S3 (5m)	0,0499	0,0186	0,015	2,68	M → E
POT(3)	S1 (5m)	0,1079	0,0484	0,000	2,23	M → E
POT(3)	S2 (10m)	0,1577	0,0375	0,005	4,21	M → E
POT(3)	S4 (10m)	0,0441	0,0155	0,035	2,84	M → E
POT(4)	S1 (5m)	0,0911	0,0910	0,000	1,00	≈ sim.
POT(4)	S2 (10m)	0,0890	0,0494	0,020	1,80	M → E
POT(4)	S3 (5m)	0,0919	0,0486	0,005	1,89	M → E
POT(4)	S4 (10m)	0,0257	0,0322	0,000	0,80	E → M
POT(5)	S1 (5m)	0,0907	0,0557	0,000	1,63	M → E
POT(5)	S2 (10m)	0,1059	0,0414	0,005	2,56	M → E
POT(5)	S3 (5m)	0,0852	0,0382	0,000	2,23	M → E
POT(5)	S4 (10m)	0,0469	0,0335	0,000	1,40	M → E
POT(6)	S1 (5m)	0,0750	0,1587	0,000	0,47	E → M
POT(6)	S2 (10m)	0,1027	0,0733	0,000	1,40	M → E
POT(6)	S3 (5m)	0,0789	0,0700	0,000	1,13	M → E
POT(6)	S4 (10m)	0,0276	0,0448	0,000	0,62	E → M
POT(7)	S1 (5m)	0,0882	0,0765	0,000	1,15	M → E
POT(7)	S3 (5m)	0,1239	0,0465	0,000	2,67	M → E
POT(7)	S4 (10m)	0,0443	0,0369	0,000	1,20	M → E
Tilt(1)	S1 (5m)	0,0685	0,0334	0,000	2,05	M → E
Tilt(2)	S1 (5m)	0,0954	0,1766	0,000	0,54	E → M
Tilt(2)	S2 (10m)	0,1464	0,1012	0,000	1,45	M → E
Tilt(2)	S3 (5m)	0,0965	0,0605	0,010	1,60	M → E

Continúa en la página siguiente

Cuadro 2: (continuación)

Serie MPT	**Sensor EPM**	$T_{\mathrm{M}\to\mathrm{E}}$ [bits]	$T_{\mathrm{E}\to\mathrm{M}}$ [bits]	$p_{\mathrm{E}\to\mathrm{M}}$	R	**Dom.**
Tilt(2)	S4 (10m)	0,0332	0,0417	0,000	0,80	$\mathrm{E}\to\mathrm{M}$
Tilt(3)	S1 (5m)	0,0704	0,1730	0,000	0,41	$\mathrm{E}\to\mathrm{M}$
Tilt(3)	S2 (10m)	0,0883	0,0889	0,000	0,99	$\mathrm{E}\to\mathrm{M}$
Tilt(3)	S3 (5m)	0,0902	0,0958	0,000	0,94	$\mathrm{E}\to\mathrm{M}$
Tilt(3)	S4 (10m)	0,0438	0,0935	0,000	0,47	$\mathrm{E}\to\mathrm{M}$
Tilt(4)	S1 (5m)	0,0754	0,2259	0,000	0,33	$\mathrm{E}\to\mathrm{M}$
Tilt(4)	S2 (10m)	0,0924	0,0978	0,000	0,94	$\mathrm{E}\to\mathrm{M}$
Tilt(4)	S3 (5m)	0,1094	0,1191	0,000	0,92	$\mathrm{E}\to\mathrm{M}$
Tilt(4)	S4 (10m)	0,0520	0,1038	0,000	0,50	$\mathrm{E}\to\mathrm{M}$
Tilt(5)	S1 (5m)	0,0707	0,1074	0,000	0,66	$\mathrm{E}\to\mathrm{M}$
Tilt(5)	S3 (5m)	0,0732	0,0758	0,000	0,97	$\mathrm{E}\to\mathrm{M}$
Tilt(5)	S4 (10m)	0,0401	0,0617	0,000	0,65	$\mathrm{E}\to\mathrm{M}$
Tilt(6)	S1 (5m)	0,1108	0,1344	0,000	0,82	$\mathrm{E}\to\mathrm{M}$
Tilt(6)	S2 (10m)	0,1175	0,0749	0,000	1,57	$\mathrm{M}\to\mathrm{E}$
Tilt(6)	S3 (5m)	0,1182	0,0738	0,000	1,60	$\mathrm{M}\to\mathrm{E}$
Tilt(6)	S4 (10m)	0,0629	0,0726	0,000	0,87	$\mathrm{E}\to\mathrm{M}$
Tilt(7)	S1 (5m)	0,0681	0,1624	0,000	0,42	$\mathrm{E}\to\mathrm{M}$
Tilt(7)	S2 (10m)	0,0905	0,0855	0,000	1,06	$\mathrm{M}\to\mathrm{E}$
Tilt(7)	S3 (5m)	0,0694	0,0933	0,000	0,74	$\mathrm{E}\to\mathrm{M}$
Tilt(7)	S4 (10m)	0,0307	0,0441	0,000	0,70	$\mathrm{E}\to\mathrm{M}$

Cuadro 3: Pares MPT–EPM con flujo **unidireccional verificado**: la dirección MPT → EPM es estadísticamente significativa ($p = 0.000$ en todos los casos), mientras que la dirección EPM → MPT no supera el umbral de significancia ($p \geq 0.05$, test de datos sustitutos, $N_s = 199$). $T_{\mathrm{E}\to\mathrm{M}}$ se muestra como valor observado no validado estadísticamente. $R = T_{\mathrm{M}\to\mathrm{E}}/T_{\mathrm{E}\to\mathrm{M}}$ no tiene interpretación causal en este caso: el denominador no está verificado. Véase también la Tabla 4.

Serie MPT	**Sensor EPM**	$T_{\mathrm{M}\to\mathrm{E}}$ [bits]	$T_{\mathrm{E}\to\mathrm{M}}$ [bits]	$p_{\mathrm{E}\to\mathrm{M}}$	**Dir. verificada**
POT(1)	S1 (5m)	0,0612	0,0121	0,065	Solo M → E
POT(1)	S2 (10m)	0,0711	0,0092	0,276	Solo M → E
POT(1)	S3 (5m)	0,0903	0,0076	0,151	Solo M → E
POT(1)	S4 (10m)	0,0321	0,0021	0,281	Solo M → E
POT(2)	S2 (10m)	0,0436	0,0196	0,070	Solo M → E
POT(2)	S4 (10m)	0,0291	0,0070	0,116	Solo M → E
POT(3)	S3 (5m)	0,1424	0,0257	0,096	Solo M → E
POT(7)	S2 (10m)	0,1267	0,0376	0,075	Solo M → E
Tilt(1)	S2 (10m)	0,0846	0,0242	0,116	Solo M → E
Tilt(1)	S3 (5m)	0,0974	0,0171	0,221	Solo M → E
Tilt(1)	S4 (10m)	0,0328	0,0112	0,050	Solo M → E

Cuadro 4: Caso especial: par Tilt(5) – S2 (10m). Es el único par del conjunto donde la dirección MPT → EPM no supera el umbral de significancia ($p = 0.055 > 0.05$), mientras que la dirección inversa EPM → MPT sí es significativa ($p = 0.000$). Este par queda excluido de la Tabla 2 y de la Tabla 3, y se reporta de forma independiente.

Serie MPT	**Sensor EPM**	$T_{\mathrm{M}\to\mathrm{E}}$ [bits]	$T_{\mathrm{E}\to\mathrm{M}}$ [bits]	$p_{\mathrm{M}\to\mathrm{E}}$ / $p_{\mathrm{E}\to\mathrm{M}}$	**Dir. verificada**
Tilt(5)	S2 (10m)	0,0621	0,0872	0,055 / 0,000	Solo E → M

Asimetría del flujo y su interpretación. La Figura 9 muestra la razón $R_{ij} = T_{\mathrm{MPT}\to\mathrm{EPM}}(\tau^*)/T_{\mathrm{EPM}\to\mathrm{MPT}}(\tau)_{\mathrm{máx}}$ para los 56 pares.

Para los 44 pares de la Tabla 2, donde ambas direcciones están verificadas estadísticamente, la razón R tiene interpretación directa. En los sensores **POT** de ese grupo la razón es consistentemente mayor que uno: POT(3) alcanza $R = 4.21$ hacia S2 y $R = 2.84$ hacia S4, y POT(5) presenta valores entre 1.40 y 2.56 en todos sus sensores EPM. Esto indica que en esos pares el MPT transfiere más información al EPM que a la inversa, con ambas magnitudes estadísticamente verificadas. Para los sensores **Tilt** dentro de ese mismo grupo la situación es distinta: Tilt(3) y Tilt(4) tienen $R < 1$ en

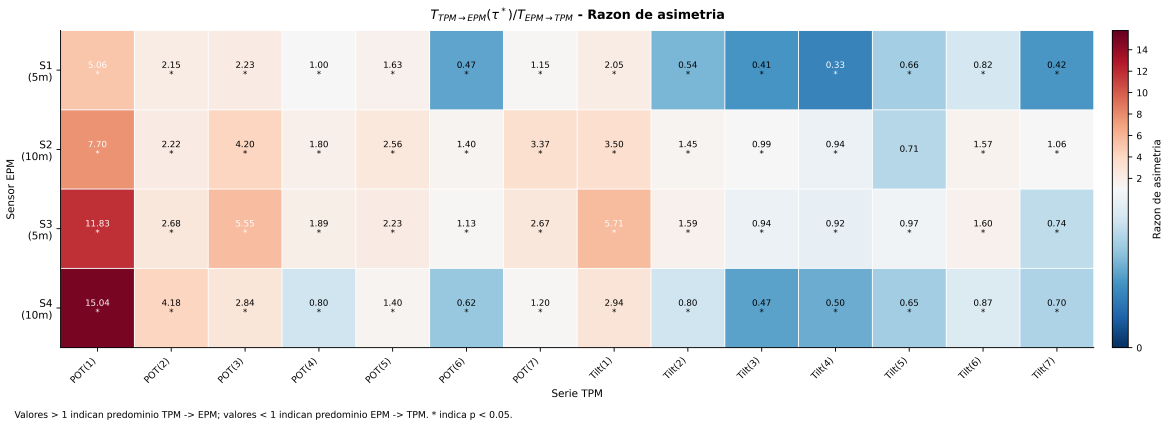


Figura 9: Razón de asimetría $T_{\mathrm{MPT}\to\mathrm{EPM}}(\tau^*)/T_{\mathrm{EPM}\to\mathrm{MPT}}(\tau)_{\mathrm{máx}}$ para los 56 pares. Valores mayores que uno (rojo) indican predominio de la dirección MPT $\to$ EPM; valores menores que uno (azul) indican predominio de EPM $\to$ MPT. El asterisco (*) indica que el par es estadísticamente significativo en la dirección MPT $\to$ EPM ($p < 0.05$).

todos sus pares, con valores entre 0.33 y 0.99, lo que indica que en esos pares el EPM transfiere más información al MPT que a la inversa.

Para los 11 pares de la Tabla 3, que incluyen todos los pares de **POT(1)**, la situación es diferente. El flujo MPT $\to$ EPM es verificado y real, pero el flujo EPM $\to$ MPT no pudo distinguirse estadísticamente del ruido de estimación. Los valores altos de R que aparecen en la figura para esos pares, como los de POT(1) que oscilan entre 5,06 y 15,04, no deben interpretarse como evidencia de que el MPT transfiere 15 veces más información, reflejan que el numerador es real y el denominador es en buena parte ruido. La interpretación correcta es más directa, existe flujo MPT $\to$ EPM verificado y no existe flujo EPM $\to$ MPT verificable.

Esta diferencia entre POT y Tilt tiene una interpretación física directa, los sensores POT miden desplazamiento lineal del perfil, que es el análogo más cercano a la deformación que registran los extensómetros. Los sensores Tilt miden rotación, una variable distinta que puede responder a modos de deformación del macizo que el EPM no captura con igual sensibilidad. Que el flujo en los pares Tilt sea bidireccional o incluso dominado por el EPM no invalida la hipótesis de la tesis. Lo relevante para el modelo MOGP es que exista un subconjunto de series del MPT que transfiera información al EPM, y los sensores POT satisfacen esa condición de manera consistente.

Síntesis del análisis estadístico. Los tres análisis de esta sección apuntan en la misma dirección. La correlación de Pearson y la Distance Correlation mostraron que los sistemas MPT y EPM comparten información sobre la dinámica del macizo en la gran mayoría de los pares del bloque cruzado, incluyendo pares donde la relación no es de tipo lineal. La Entropía de Transferencia agrega algo que esas medidas simétricas no podían aportar, y es que la relación tiene carácter dinámico y su dirección predominante es MPT $\to$ EPM en los sensores POT, que son los análogos cinemáticos más directos

de los extensómetros. Esto no es un resultado trivial, porque la correlación entre los dos sistemas por sí sola no garantiza que el MPT sea útil para inferir el EPM. Podría ocurrir que ambos respondieran a una señal externa común sin que el pasado de uno redujera la incertidumbre sobre el futuro del otro. El análisis de TE muestra que no es así. Con esta evidencia, la hipótesis central de la tesis queda validada estadísticamente, y es que el MPT contiene información geotécnica del sistema general, y no es despreciable para justificar su incorporación como fuente auxiliar en el MOGP, y la dominancia de los sensores POT en esa transferencia es coherente para la construcción de los datos de los sensores del monitoreo EPM.

8. Cronograma

El desarrollo de la investigación se organiza en catorce meses de trabajo distribuidos en las siguientes actividades:

Cuadro 5: Cronograma de actividades de la tesis de maestría. Período: 2025 – diciembre 2026 (15 meses). Actividades organizadas por objetivo específico (OE1–OE4) según la metodología propuesta. **Leyenda:** *Completado* *En curso (julio 2026)* *Planificado*

Actividad	2025			2026											
	Oct	Nov	Dic	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
Revisión bibliográfica y preparación general															
a. Revisión bibliográfica y estado del arte	■	■	■	■											
b. Estudio del modelo constitutivo de Nishihara		■	■	■	■										
OE1 — Validación estadística de la dependencia MPT → EPM															
c. Limpieza y alineación temporal de las series EPM–MPT			■	■	■										
d. Correlaciones de Pearson, Spearman y función cruzada (CCF)				■	■	■									
e. Distance Correlation e Información Mutua (Székely et al., 2007)					■	■									
f. Transfer Entropy MPT → EPM — surrogate test (Schreiber, 2000)						■	■	■	■	■					
OE2 — Derivación analítica del kernel de Nishihara															
g. Operador diferencial lineal de Nishihara y función de Green										■	■				
h. Derivación de los bloques k_{EE}, k_{TE} y k_{TT} en forma cerrada											■	■			
i. Demostración formal de semidefinición positiva de $\mathbf{K}(t,t')$												■			
j. Verificación numérica de la semidefinición positiva (valores propios)												■			
OE3 — Implementación del MOGP y reconstrucción de la brecha EPM															
k. Exploración de GPflow y GPyTorch — problema simplificado												■	■		
l. Ajuste de hiperparámetros — log-verosimilitud marginal (simplificado)												■	■		
m. Implementación del kernel con restricción física (Nishihara)													■		
n. Estimación de $\{E_0, E_1, \eta_1\}$ y comparación con ensayos													■		
o. Reconstrucción de las 4 series EPM en $[t_1, t_2]$ con incertidumbre													■	■	
p. Validación cruzada: brechas artificiales de 1 sem., 1 mes y 3 meses														■	
q. Métricas RMSE, MAE y evaluación cuantitativa del modelo														■	
OE4 — Estudio de ablación progresivo															
r. GP univariado por canal EPM sin fuente auxiliar (línea base)														■	
s. MOGP con kernel estándar (RBF/Matérn) + MPT como fuente auxiliar														■	
t. MOGP completo con kernel de Nishihara — cuantificación del aporte físico														■	■
u. Tabla comparativa de métricas e interpretación geotécnica															■
Escritura del documento final															
v. Redacción progresiva de capítulos y generación de figuras										■	■	■	■	■	
w. Revisión, corrección y entrega del documento final														■	■

9. Recursos

- Acceso completo a los datos de monitoreo EPM y MPT del túnel.
- Acceso a bases de datos científicas especializadas (ScienceDirect, Springer Link, arXiv).
- Computador con software de programación numérica y científica (Python, `GPflow`, `GPyTorch`, NumPy, SciPy, Matplotlib).

Referencias

[1] Álvarez, M. A., Luengo, D., & Lawrence, N. D. (2009). Latent force models. In *Proceedings of the 12th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 9–16.

[2] Álvarez, M. A., Rosasco, L., & Lawrence, N. D. (2012). *Kernels for Vector-Valued Functions: A Review*. Foundations and Trends in Machine Learning, 4(3), 195–266.

[3] Dalmasso, M., Civera, M., De Biagi, V., & Chiaia, B. (2025). Gaussian Process Regression (GPR)-based missing data imputation and its uses for bridge structural health monitoring. *Advances in Bridge Engineering*, 6, 23.

[4] Kennedy, M. C., & O'Hagan, A. (2000). Predicting the output from a complex computer code when fast approximations are available. *Biometrika*, 87(1), 1–13.

[5] Li, C., Sharma, H., Wu, Y., Magallanes, J., Ramesh, K. T., & Shields, M. D. (2026). Physics-Informed Gaussian Process Regression for the Constitutive Modeling of Concrete. *arXiv*:2601.03367.

[6] Long, H., Lu, X., Ma, C., Li, T., Yan, W., Zhang, H., & Dai, K. (2024). A dynamic learning method based on the Gaussian process for tunnel boring machine intelligent driving. *Frontiers in Earth Science*, 11, 1121318.

[7] Mason, A., Best, N., Plewis, I., & Richardson, S. (2010). Insights into the use of Bayesian models for informative missing data. Technical report, Imperial College.

[8] Onalo, D., Adedigba, S., Oloruntobi, O., Khan, F., James, L. A., & Butt, S. (2020). Data-driven model for shear wave transit time prediction for formation evaluation. *Journal of Petroleum Exploration and Production Technology*, 10, 1429–1447.

[9] Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2017). Machine learning of linear differential equations using Gaussian processes. *Journal of Computational Physics*, 348, 683–693.

[10] Rasmussen, C. E., & Williams, C. K. I. (2006). *Gaussian Processes for Machine Learning*. MIT Press.

[11] Székely, G. J., Rizzo, M. L., & Bakirov, N. K. (2007). Measuring and testing dependence by correlation of distances. *The Annals of Statistics*, 35(6), 2769–2794.

[12] Titsias, M. K. (2009). Variational Learning of Inducing Variables in Sparse Gaussian Processes. In *Proceedings of the 12th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 567–574.

[13] Wang, W., Khalil, M. M. Y., & Bayisa, L. Y. (2024). Online variational Gaussian process for time series data. *Journal of Big Data*, 11, 174.

[14] Yuan, B., Choo, C. S., Yeo, L. Y., et al. (2025). Physics-informed machine learning in geotechnical engineering: a direction paper. *Geomechanics and Geoengineering*, 20(5), 1128–1159.

[15] Zhang, Z., Dias, D., Anitescu, C., Pan, Q., & Rabczuk, T. (2025). Physics-informed neural network for elastic-plastic mesh-free modelling of tunnelling-induced deformation. *Acta Geotechnica*.

[16] Schreiber, T. (2000). Measuring information transfer. *Physical Review Letters*, 85(2), 461–464.

[17] Theiler, J., Eubank, S., Longtin, A., Galdrikian, B., & Farmer, J. D. (1992). Testing for nonlinearity in time series: the method of surrogate data. *Physica D: Nonlinear Phenomena*, 58(1–4), 77–94.

[18] Vicente, R., Wibral, M., Lindner, M., & Pipa, G. (2011). Transfer entropy—a model-free measure of effective connectivity for the neurosciences. *Journal of Computational Neuroscience*, 30(1), 45–67.

[19] Hu, D., Liang, X., Li, Y., Wu, Y., & Jiang, L. (2022). Deformation prediction of tunnel-surrounding rock considering the time effect of the viscosity coefficient: a case of an NATM-excavated tunnel. *Frontiers in Earth Science*, 10, 843545.

[20] Zhao, J., Tan, Z., Zhou, Z., & Ma, X. (2023). The secondary development and application of the improved Nishihara creep model in soft rock tunnels. *Buildings*, 13(8), 2082.

[21] Gourévitch, B., & Eggermont, J. J. (2007). Evaluating information transfer between auditory cortical neurons. *Journal of Neurophysiology*, *97*(3), 2533–2543.